

# Resumen de los Resultados

Grupo: Desirée Vera, Felipe Gómez, Harmynn Garrido, Diego Granados.

## Parte A: Modelos

Se entrenaron dos modelos de clasificación para determinar los defaults. El primero consiste en modelo logit, en el cual se utilizaron todas las variables explicativas para predecir a la variable objetivo Default.

El segundo se basó en un árbol de decisión optimizado con un max depth = 7, min\_samples\_leaf = 10 , min\_samples\_split = 2 y random\_state = 21.

Como se mencionó en el Análisis Exploratorio de Datos, la variable 'Default' presenta una leve asimetría, dado que el 63% de los registros corresponde a 1 (hubo default). El desbalanceo sesga al indicador Accuracy hacia el valor mayoritario, por lo que este indicador debe ser contrastado con lo que diga el Recall y la Precision. Esto nos llevó a optimizar los modelos usando el F1 Score, previniendo cualquier sesgo que pueda producir el desbalanceo.

## Parte B: Resultados

Al revisar las matrices de confusión con la muestra de test , notamos la similitud en los resultados.

Matriz de confusión modelo de regresión logística -Test

	Predicción 0	Predicción 1
Real 0	546	817
Real 1	129	2215

Matriz de confusión modelo árbol de decisión -Test


	Predicción 0	Predicción 1
Real 0	484	879
Real 1	108	2236

Ambos modelos presentan bastantes falsos positivos, personas fueron clasificadas como riesgo de default cuando no lo eran.

Esto puede ser aceptable si el objetivo es minimizar el riesgo financiero, pero podría tener implicaciones si se usa para rechazar solicitudes de crédito.

La existencia más falsos positivos que falsos negativos puede ser reflejo del desbalance de los datos en la variable Default.

Los también modelos arrojan resultados similares en la curva ROC, dónde el modelo de regresión logística tiene mejor ajuste en la predicción en la muestra de entrenamiento (0,84) y con la muestra test (0,84).



Cuando comparamos las métricas en general se constata que el modelo de regresión logística en la muestra test presenta mejores resultados, mayor KS, mayor Accuracy. Sin embargo, el Recall favorece al modelo tree y la Precision al modelo logit. En ese sentido, el F1 Score, que muestra un balance entre ambos termina favoreciendo al Modelo logit, que es el que escogimos.

Tabla comparativa de modelos:

	Modelo	Muestra	AUC	KS	Threshold	Accuracy	Precision	Recall	F1
0	logit_sk	Train	0.844878	0.513741	0.260706	0.763788	0.749782	0.940822	0.834508
1	logit_sk	Test	<b>0.838633</b>	0.516637	0.239813	<b>0.744807</b>	<b>0.730541</b>	0.944966	<b>0.824033</b>
2	tree	Train	0.817260	0.488966	0.414634	0.754422	0.742369	0.937352	0.828544
3	tree	Test	0.810299	0.478983	0.403785	0.733747	0.717817	<b>0.953925</b>	0.819198

### **Parte C: Escogencia de modelo**

Dada la revisión de resultados, se escoge el Modelo logit.